

RAG com HuggingFace

Arquitetura de Recuperação e Geração: Criando IA Factual, Segura e Contextualizada em Python.

ARTHUR RENZO · GABRIEL BALBINO FERRI · RAFAEL BOTARO DA SILVA

Por que implementar o RAG?

O Problema

LLMs tradicionais possuem "conhecimento estático".
Eles alucinam quando não sabem uma resposta e não
têm acesso a documentos privados ou atualizados da
empresa.

A Solução

O RAG atua como uma "memória externa". Ele recupera fatos de uma base de dados proprietária e os entrega para a IA, garantindo respostas precisas e fundamentadas.



A Stack Tecnológica



MiniLM L12

Modelo de **Embeddings** multilíngue que transforma texto em vetores matemáticos para busca semântica.



FAISS

Biblioteca de alta performance para **Busca Vetorial**, permitindo encontrar contextos em milissegundos.



Qwen 0.5B

Modelo de Linguagem (**LLM**) otimizado para rodar em hardware leve como o Google Colab.

